

# Probabilistic Parsing


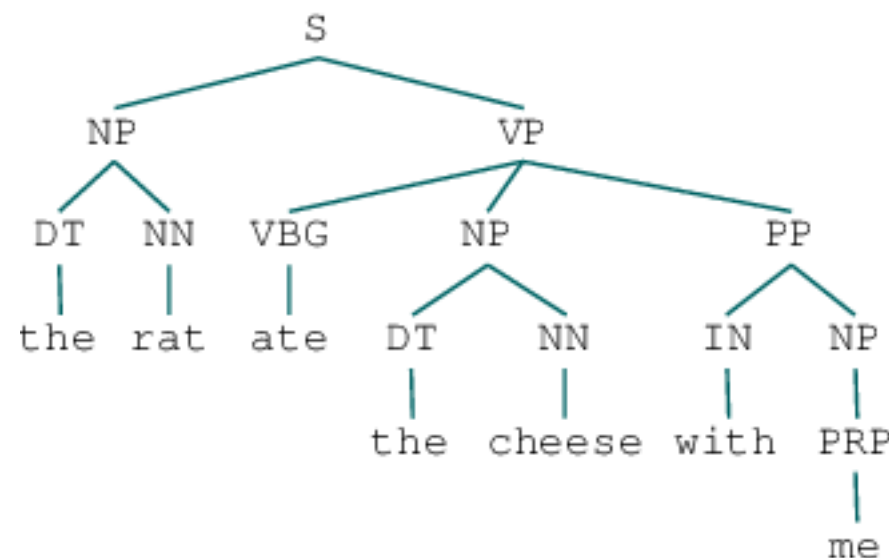
COMP90042 LECTURE 18



THE UNIVERSITY OF  
MELBOURNE

# Ambiguity in parsing

- Context-free grammars assign hierarchical structure to language
  - \* Linguistic notion of a '*syntactic constituent*'
  - \* Formulated as generating all strings in the language; or
  - \* Predicting the structure(s) for a given string
- Raises problem of ambiguity, e.g., which is better?



# Outline

- Probabilistic context-free grammars (PCFGs)
- Parsing using dynamic programming
- Limitations of 'context-free' assumption and some solutions:
  - \* parent annotation
  - \* head lexicalisation

# Basics of Probabilistic CFGs

- As for CFGs, same symbol set:
  - \* Terminals: words such as *book*
  - \* Non-terminal: syntactic labels such as NP or NN
- Same productions (rules)
  - \* LHS non-terminal  $\rightarrow$  ordered list of RHS symbols
- In addition, store a **probability** with each production
  - \*  $\text{NP} \rightarrow \text{DT NN}$   $[p = 0.45]$
  - \*  $\text{NN} \rightarrow \text{cat}$   $[p = 0.02]$
  - \*  $\text{NN} \rightarrow \text{leprechaun}$   $[p = 0.00001]$
  - \* ...

# Probabilistic CFGs

- Probability values denote *conditional*
  - \*  $\Pr(\text{RHS} \mid \text{LHS})$
- Consequently they:
  - \* must be positive values, between 0 and 1
  - \* must sum to one for given LHS
- E.g.,
  - \*  $\text{NN} \rightarrow \text{aadvark} \quad [p = 0.0003]$
  - \*  $\text{NN} \rightarrow \text{cat} \quad [p = 0.02]$
  - \*  $\text{NN} \rightarrow \text{leprechaun} \quad [p = 0.0001]$
  - \*  $\sum_x \Pr(\text{NN} \rightarrow x \mid \text{NN}) = 1$

# A Probabilistic grammar

Grammar		Lexicon
$S \rightarrow NP VP$	[.80]	$Det \rightarrow that [.10] \mid a [.30] \mid the [.60]$
$S \rightarrow Aux NP VP$	[.15]	$Noun \rightarrow book [.10] \mid \text{flights} [.30]$
$S \rightarrow VP$	[.05]	$\mid meal [.015] \mid money [.05]$
$NP \rightarrow Pronoun$	[.35]	$\mid flight [.40] \mid dinner [.10]$
$NP \rightarrow Proper-Noun$	[.30]	$Verb \rightarrow book [.30] \mid include [.30]$
$NP \rightarrow Det Nominal$	[.20]	$\mid prefer [.40]$
$NP \rightarrow Nominal$	[.15]	$Pronoun \rightarrow I [.40] \mid she [.05]$
$Nominal \rightarrow Noun$	[.75]	$\mid me [.15] \mid you [.40]$
$Nominal \rightarrow Nominal Noun$	[.20]	$Proper-Noun \rightarrow Houston [.60]$
$Nominal \rightarrow Nominal PP$	[.05]	$\mid NWA [.40]$
$VP \rightarrow Verb$	[.35]	$Aux \rightarrow does [.60] \mid can [.40]$
$VP \rightarrow Verb NP$	[.20]	$Preposition \rightarrow from [.30] \mid to [.30]$
$VP \rightarrow Verb NP PP$	[.10]	$\mid on [.20] \mid near [.15]$
$VP \rightarrow Verb PP$	[.15]	$\mid through [.05]$
$VP \rightarrow Verb NP NP$	[.05]	
$VP \rightarrow VP PP$	[.15]	
$PP \rightarrow Preposition NP$	[1.0]	

Source JM3, Fig 12.1

# Stochastic Generation with PCFGs

Déjà vu, it's almost the same as for CFG, with one twist:

1. Start with S, the sentence symbol
2. Choose a rule with S as the LHS
  - \* **Randomly select a RHS** according to  $\text{Pr}(\text{RHS} \mid \text{LHS})$   
e.g.,  $S \rightarrow VP$
  - \* Apply this rule, e.g., substitute VP for S
3. Repeat step 2 for each non-terminal in the string  
(here, VP)
4. Stop when no non-terminals remain

Gives us a tree, as before, with a sentence as the yield

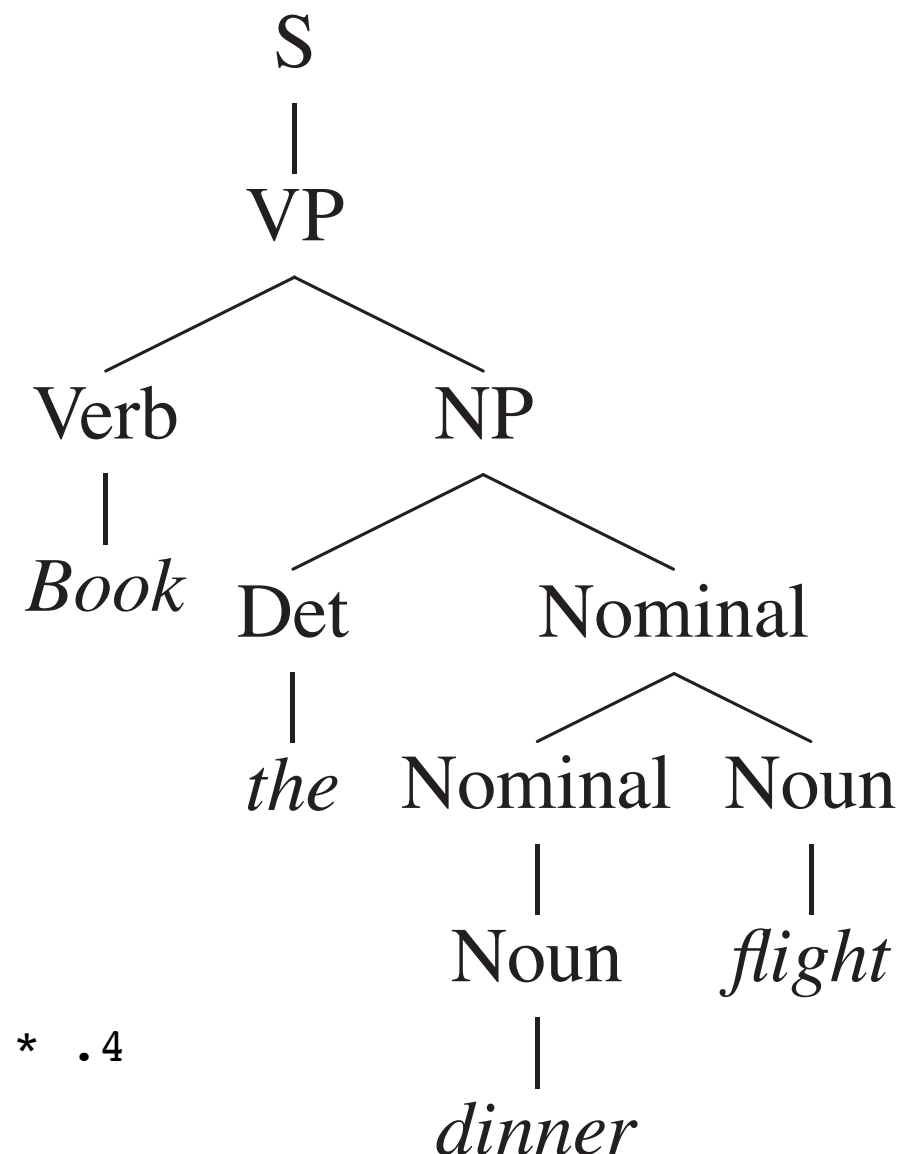
# How likely is a tree?

- Given a tree, we can compute its probability
  - Decomposes into probability of each production

- E.g., for tree on right,

\*  $P(\text{tree}) =$

$P(S \rightarrow VP) \times$   
 $P(VP \rightarrow \text{Verb NP}) \times$   
 $P(\text{Verb} \rightarrow \textit{Book}) \times$   
 $P(NP \rightarrow \text{Det Nominal}) \times$   
 $P(\text{Det} \rightarrow \textit{the}) \times$   
 $P(\text{Nominal} \rightarrow \text{Nominal Noun}) \times$   
 $P(\text{Nominal} \rightarrow \text{Noun}) \times$   
 $P(\text{Noun} \rightarrow \textit{dinner}) \times$   
 $P(\text{Noun} \rightarrow \textit{flight}) = 2.16 \times 10^{-6}$

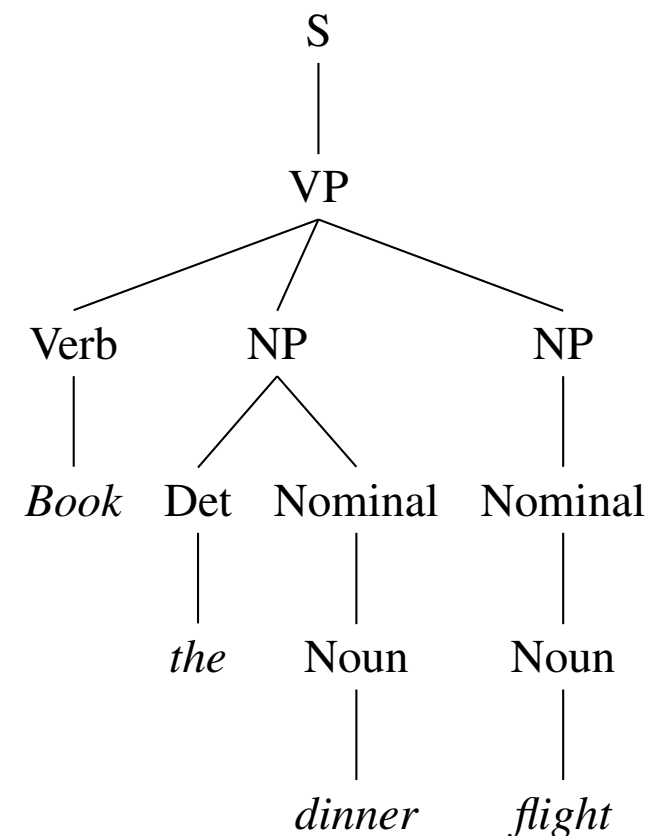
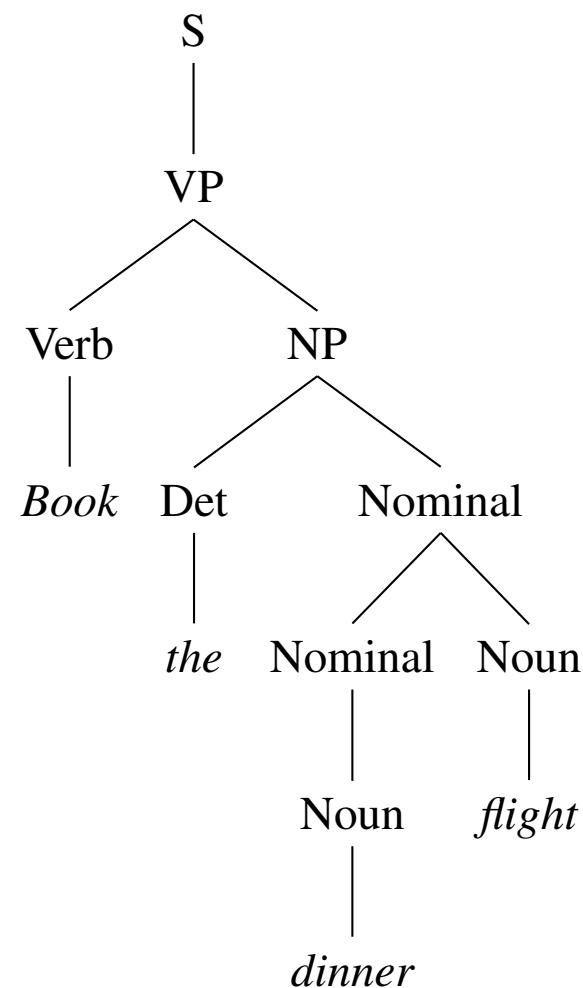


I.e.,  $.05 * .2 * .3 * .2 * .6 * .2 * .75 * .1 * .4$



# Resolving parse ambiguity

- Can select between different trees based on  $P(T)$



Source: JM3  
Fig 12.2

Mistakes in  
textbook

$.05 * .05 * .20 * .15 * .75 * .75 * .30 * .60 * .10 * .40$

- $P = 2.16 \times 10^{-6}$

$$P = 3.04 \times 10^{-7}$$

# Parsing PCFGs

- Instead of selecting between two trees, can we select a tree from the set of all possible trees?
- Before we looked at
  - \* CYK and Early
  - \* for unweighted grammars (CFGs)
  - \* finds **all possible trees**
- But there are often 1000s, many completely nonsensical  $\arg \max_T \text{ s.t. } \text{yield}(T)=\mathbf{w} P(T)$
- Can we solve for the **most probable tree**

# CYK for PCFGS

- CYK finds *all trees* for a sentence; we want **best** tree
- Prob. CYK follows similar process to standard CYK
- Convert grammar to Chomsky Normal Form (CNF)

\* E.g.,  $VP \rightarrow \text{Verb NP NP}$  **[0.05]**

becomes  $VP \rightarrow \text{Verb NP+NP}$  **[ ]**  
 $NP+NP \rightarrow NP NP$  **[ ]**

where NP+NP is a new symbol.

- Issues with unary productions (*see ipython notebook*)

# Prob. CYK

```

function PROBABILISTIC-CYK(words, grammar) returns most probable parse
                                     and its probability

for  $j \leftarrow$  from 1 to LENGTH(words) do
    for all  $\{ A \mid A \rightarrow words[j] \in grammar \}$ 
         $table[j-1, j, A] \leftarrow P(A \rightarrow words[j])$ 
    for  $i \leftarrow$  from  $j-2$  downto 0 do
        for  $k \leftarrow i+1$  to  $j-1$  do
            for all  $\{ A \mid A \rightarrow BC \in grammar,$ 
                        and  $table[i, k, B] > 0$  and  $table[k, j, C] > 0 \}$ 
                if  $(table[i, j, A] < P(A \rightarrow BC) \times table[i, k, B] \times table[k, j, C])$  then
                     $table[i, j, A] \leftarrow P(A \rightarrow BC) \times table[i, k, B] \times table[k, j, C]$ 
                     $back[i, j, A] \leftarrow \{k, B, C\}$ 
    return BUILD_TREE( $back[1, LENGTH(words), S]$ ),  $table[1, LENGTH(words), S]$ 

```

**Figure 12.3** The probabilistic CYK algorithm for finding the maximum probability parse

chart now stores  
probabilities for each  
span and symbol

**function** CKY-PARSE(*words*, *grammar*) **returns** *table*

**for** *j* ← **from** 1 **to** LENGTH(*words*) **do**

**for all** {*A* |  $A \rightarrow \text{words}[j] \in \text{grammar}$ }

$\text{table}[j-1, j] \leftarrow \text{table}[j-1, j] \cup A$

**for** *i* ← **from** *j* - 2 **downto** 0 **do**

**for** *k* ← *i* + 1 **to** *j* - 1 **do**

**for all** {*A* |  $A \rightarrow BC \in \text{grammar}$  **and** *B* ∈ *table*[*i*, *k*] **and** *C* ∈ *table*[*k*, *j*]}

$\text{table}[i, j] \leftarrow \text{table}[i, j] \cup A$

**Figure 11.5** The CKY algorithm.

validity test now looks to  
see that the child chart cells  
have non-zero probability

**function** PROBABILISTIC-CKY(*words*, *grammar*) **returns** most probable parse  
and its probability

**for** *j* ← **from** 1 **to** LENGTH(*words*) **do**

**for all** {*A* |  $A \rightarrow \text{words}[j] \in \text{grammar}$ }

$\text{table}[j-1, j, A] \leftarrow P(A \rightarrow \text{words}[j])$

**for** *i* ← **from** *j* - 2 **downto** 0 **do**

**for** *k* ← *i* + 1 **to** *j* - 1 **do**

**for all** {*A* |  $A \rightarrow BC \in \text{grammar}$ ,

**and**  $\text{table}[i, k, B] > 0$  **and**  $\text{table}[k, j, C] > 0$ }

**if** ( $\text{table}[i, j, A] < P(A \rightarrow BC) \times \text{table}[i, k, B] \times \text{table}[k, j, C]$ ) **then**

$\text{table}[i, j, A] \leftarrow P(A \rightarrow BC) \times \text{table}[i, k, B] \times \text{table}[k, j, C]$

$\text{back}[i, j, A] \leftarrow \{k, B, C\}$

**return** BUILD\_TREE( $\text{back}[1, \text{LENGTH}(\text{words}), S]$ ),  $\text{table}[1, \text{LENGTH}(\text{words}), S]$

Instead of storing set  
of symbols, store the  
probability of best scoring  
tree fragment covering span  
[*i*, *j*] with root symbol *A*

Overwrite lower scoring  
analysis if this one is better,  
and record the best production.

**Figure 12.3** The probabilistic CKY algorithm for finding the maximum probability parse

# Illustration

we eat sushi with chopsticks

1				
$\frac{1}{2}$				
$\frac{1}{4}$				
$\frac{1}{8}$				
$\frac{1}{8}$				
1				
1				
$\frac{1}{2}$				
$\frac{1}{4}$				

S	→ NP VP	1
NP	→ NP PP	1/2
	→ we	1/4
	→ sushi	1/8
	→ chopsticks	1/8
PP	→ IN NP	1
IN	→ with	1
VP	→ V NP	1/2
	→ VP PP	1/4
	→ MD V	1/4
V	→ eat	1

*Example & grammar from E18 Chapter 10*

# Illustration

we eat sushi with chopsticks

NP	1/4				
	1				
	1/2				
	1/4				
cks	1/8				
	1/8				
	1				
	1				
	1/2				
	1/4				

S	→ NP VP	1
NP	→ NP PP	1/2
	→ we	1/4
	→ sushi	1/8
	→ chopsticks	1/8
PP	→ IN NP	1
IN	→ with	1
VP	→ V NP	1/2
	→ VP PP	1/4
	→ MD V	1/4
V	→ eat	1

# Illustration

	we	eat	sushi	with	chopsticks
NP	1/4				
		V 1			
1					
1/2					
1/4					
1/8					
1/8					
1					
1					
1/2					
1/4					

S	→ NP VP	1
NP	→ NP PP	1/2
	→ we	1/4
	→ sushi	1/8
	→ chopsticks	1/8
PP	→ IN NP	1
IN	→ with	1
VP	→ V NP	1/2
	→ VP PP	1/4
	→ MD V	1/4
V	→ eat	1



# Illustration

we eat sushi with chopsticks

NP	1/4				
	V	1			
			NP	1/8	

- S → NP VP 1
- NP → NP PP 1/2
  - we 1/4
  - sushi 1/8
  - chopsticks 1/8
- PP → IN NP 1
- IN → with 1
- VP → V NP 1/2
  - VP PP 1/4
  - MD V 1/4
- V → eat 1

# Illustration

	we	eat	sushi	with	chopsticks
	NP 1/4				
		V 1	VP $1/8 * 1 * 1/2 = 1/16$		
	1				
	1/2				
	1/4				
	1/8				
cks	1/8				
	1				
	1				
	1/2				
	1/4				

S	→ NP VP	1
NP	→ NP PP	1/2
	→ we	1/4
	→ sushi	1/8
	→ chopsticks	1/8
PP	→ IN NP	1
IN	→ with	1
VP	→ V NP	1/2
	→ VP PP	1/4
	→ MD V	1/4
V	→ eat	1

# Illustration

we eat sushi with chopsticks

NP 1/4				
	V 1	VP 1/16		
		NP 1/8		
			IN 1	

- S → NP VP 1
- NP → NP PP 1/2
  - we 1/4
  - sushi 1/8
  - chopsticks 1/8
- PP → IN NP 1
- IN → with 1
- VP → V NP 1/2
  - VP PP 1/4
  - MD V 1/4
- V → eat 1

# Illustration

we eat sushi with chopsticks

--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--

- S → NP VP 1
- NP → NP PP 1/2
  - we 1/4
  - sushi 1/8
  - chopsticks 1/8
- PP → IN NP 1
- IN → with 1
- VP → V NP 1/2
  - VP PP 1/4
  - MD V 1/4
- V → eat 1

# Illustration

we eat sushi with chopsticks

NP 1/4				
	V 1	VP 1/16		
		NP 1/8		
			IN 1	PP 1/8
				NP 1/8

S → NP VP 1

NP → NP PP 1/2

→ we 1/4

→ sushi 1/8

→ chopsticks 1/8

PP → IN NP 1

IN → with 1

VP → V NP 1/2

→ VP PP 1/4

→ MD V 1/4

V → eat 1

# Illustration

we	eat	sushi	with	chopsticks
NP 1/4				
	V 1	VP 1/16		
		NP 1/8		NP 1/128
			IN 1	PP 1/8
				NP 1/8

- S → NP VP 1
- NP → NP PP 1/2
- we 1/4
- sushi 1/8
- chopsticks 1/8
- PP → IN NP 1
- IN → with 1
- VP → V NP 1/2
- VP PP 1/4
- MD V 1/4
- V → eat 1

# Illustration

we eat sushi with chopsticks

NP	1/4				
		V	1	VP	1/16
					VP $\frac{1}{2} * 1 * \frac{1}{128} =$ 1/256
				NP	1/8
					NP 1/128
				IN	1
					PP 1/8
					NP 1/8

1/256 > 1/512  
→ this is a better analysis, so replace old value

- S → NP VP 1
- NP → NP PP 1/2
  - we 1/4
  - sushi 1/8
  - chopsticks 1/8
- PP → IN NP 1
- IN → with 1
- VP → V NP 1/2
  - VP PP 1/4
  - MD V 1/4
- V → eat 1

# Illustration

we eat sushi with chopsticks

--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--

- S → NP VP 1
- NP → NP PP 1/2
  - we 1/4
  - sushi 1/8
  - chopsticks 1/8
- PP → IN NP 1
- IN → with 1
- VP → V NP 1/2
  - VP PP 1/4
  - MD V 1/4
- V → eat 1



# Illustration

we eat sushi with chopsticks

NP 1/4				S 1/4096
	V 1	VP 1/16		VP 1/256
		NP 1/8		NP 1/128
			IN 1	PP 1/8
				NP 1/8

S	→ NP VP	1
NP	→ NP PP	1/2
	→ we	1/4
	→ sushi	1/8
	→ chopsticks	1/8
PP	→ IN NP	1
IN	→ with	1
VP	→ V NP	1/2
	→ VP PP	1/4
	→ MD V	1/4
V	→ eat	1

# Prob CYK: Retrieving The parses

- S in the top-right corner of parse table indicates success
- Retain back-pointer to best analysis
  - \* for each chart cell, store the split point and the non-terminal for the left and right children
- To get parse(s), follow pointers back for each match
- Convert back from CNF by removing new non-terminals

# Complexity of CYK

- What's the space and time complexity of this algorithm?
  - \* in terms of  $n$  the length of the input sentence

# Problems with (P)CFGs


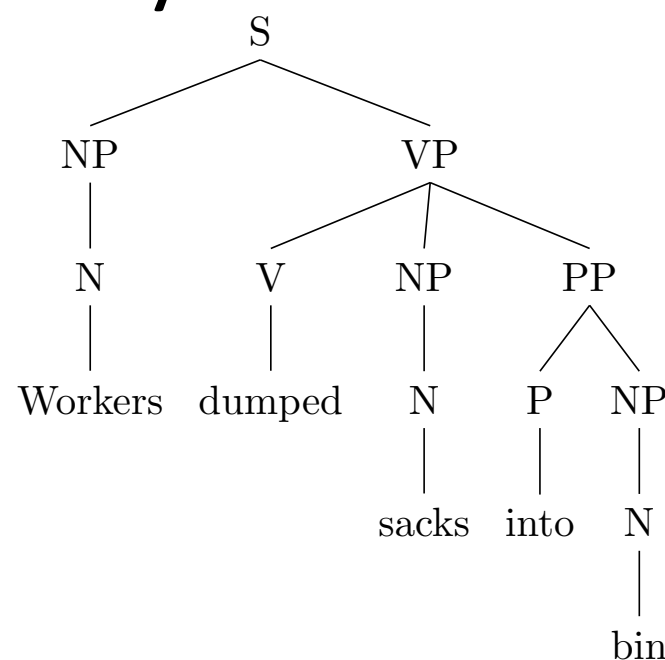
- **poor independence assumptions:** rewrite decisions made independently, whereas inter-dependence is often needed to capture global structure.
  - \* E.g., NP → PRP used often as subject (first NP), much less often as object (second NP)
- **lack of lexical conditioning:** non-terminals representation behaviour of the actual words, but are much too coarse.  
Problems with
  - \* preposition attachment ambiguity;
  - \* subcategorisation (*[forgot NP]* vs *[forgot S]*);
  - \* coordinate structure ambiguities (*dogs in houses and cats*)

# PP Attachment

- Consider sentences (PP shown bracketed)
  - (1) *Workers dumped sacks [into bin].*
  - (2) *Fishermen caught tons [of herring].*
- Both have same POS tag sequence, but different structure
  - \* PP attaches either high (to the verb) or low (to the noun)
  - \* how to make this attachment decision? Difference between the two analyses comes down to rules:
    - $VP \rightarrow \text{Verb NP PP}$                       vs.    $VP \rightarrow \text{Verb NP}; NP \rightarrow NP PP$
- The probabilities of these three rules drive attachment, *irrespective of the verb, preposition and noun*

# One solution: parent conditioning

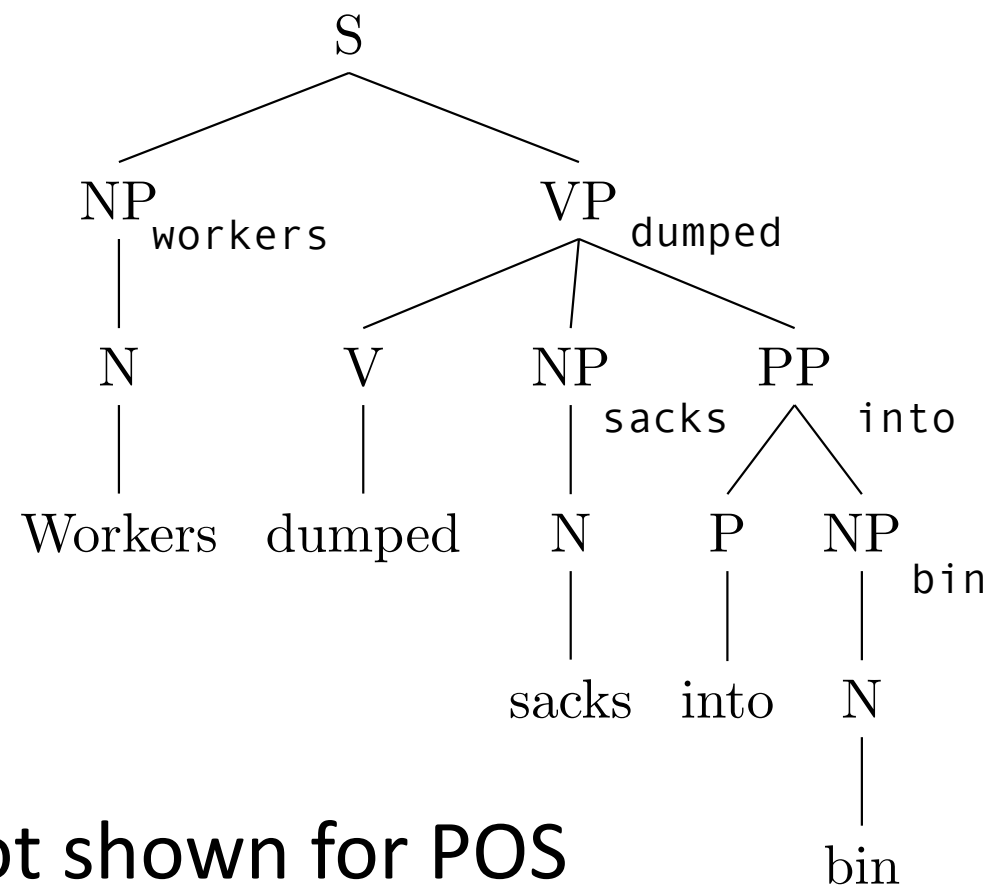
- Make non-terminals more explicit by incorporating parent symbol into each symbol



- NP^S represents subject position (left); NP^VP denotes object position (right); PP^VP is different to PP^NP
- Helps to make general tags more specific, used for a number of different purposes, e.g., *He said **that** I saw ...*

# Another solution: Head Lexicalisation

- Record **head word** with parent symbols
  - the most salient child of a constituent, usually the noun in a NP, verb in a VP etc



- head words not shown for POS
- $VP \rightarrow V NP PP \Rightarrow$   
 $VP(dumped) \rightarrow V(dumped) NP(sacks) PP(into)$

# Head lexicalisation

- Incorporate head words into productions, such that the most important links between words is captured
  - \* rule captures correlations between head tokens of phrases
- Grammar symbol inventory expands massively!
  - \* Many of the productions much too specific, seen very rarely
  - \* Learning more involved to avoid sparsity problems (e.g., zero probabilities)



# A final word

- PCFGs widely used, and are some of the best performing parsers available. E.g.,
  - \* Collins parser, Berkeley parser, Stanford parser
  - \* all use some form of lexicalisation or change to non-terminal set with CFGs
- But not used universally, a competing method is to treat parsing as a sequential process of “transitions”
  - \* next week, dependency parsing

# Required Reading

- J&M3 Ch. 12 – 12.6
  - \* Warning: several errors in the computations, and grammar used for PCYK is not in CNF